



Univerzitet u Nišu
Elektronski fakultet



Prepoznavanje znakovnog jezika u realnom vremenu primenom dubokih neuronskih mreža

Seminarski rad

Mentor: Prof. dr Aleksandar Milosavljević

Studenti: Iva Blagojević, 2137
Ljiljana Stojičić, 2136

Sadržaj

Sadržaj.....	2
1. Uvod	3
2. Skup podataka	4
2.1. Izbor podskupa znakova	4
2.2. Podela podataka po osobi	4
3. Korišćene tehnologije.....	4
4. Arhitektura sistema	5
5. Obrada podataka	6
5.1. Ekstrakcija ključnih tačaka.....	6
5.2. Priprema sekvenci.....	7
5.3. Normalizacija.....	7
5.4. Augmentacija podataka	7
6. Implementirani modeli.....	7
6.1. LSTM model.....	8
6.2. Transformer model	8
6.3. Postupak obuke	8
7. Rezultati i analiza	9
7.1. Poređenje modela	9
7.2. Analiza grešaka	10
7.3. Vizuelizacija	13
8. Problemi i rešenja	14
9. Zaključak.....	15
10. Literatura	16

1. Uvod

Znakovni jezik je primarno sredstvo komunikacije za gluve i nagluve osobe. Automatsko prepoznavanje znakova ima potencijal da olakša komunikaciju između osoba koje koriste znakovni jezik i onih koje ga ne poznaju, kao i da posluži u edukativne svrhe za učenje znakova. Cilj ovog projekta je razvoj sistema koji na osnovu pokreta ruku prepoznaje pojedinačne znakove (reči) znakovnog jezika.

Osnovna ideja sistema je da se znak ne prepoznaje iz sirovih video snimaka, već iz ključnih tačaka koje opisuju položaj šaka i gornjeg dela tela. Iz svakog frejma video snimka se pomoću alata MediaPipe izdvajaju koordinate tačaka šaka i poze, čime se problem svodi sa obrade slika na obradu nizova koordinata kroz vreme. Takav pristup značajno smanjuje količinu podataka potrebnu za obuku i omogućava rad u realnom vremenu na običnom računaru.

U okviru projekta implementirana su i upoređena dva pristupa za klasifikaciju sekvenci ključnih tačaka: rekurentna neuronska mreža zasnovana na LSTM ćelijama i model zasnovan na Transformer arhitekturi. Oba modela su obučena i evaluirana pod istim uslovima, što omogućava njihovo pošteno poređenje i predstavlja istraživačku komponentu projekta.

Izveštaj je organizovan na sledeći način: nakon uvoda, opisan je korišćeni skup podataka i razlozi za njegov izbor, zatim korišćene tehnologije i arhitektura sistema. Nakon toga detaljno je opisana obrada podataka, implementirani modeli, te ostvareni rezultati i njihova analiza. Na kraju su izneti problemi na koje se naišlo tokom izrade i zaključak sa mogućim pravcima daljeg razvoja.

2. Skup podataka

Za obuku i evaluaciju modela korišćen je skup podataka ASL Citizen, koji je razvio Microsoft Research. Skup sadrži oko 84.000 video snimaka za 2.731 znak američkog znakovnog jezika, pri čemu su snimci nastali od strane 52 različite osobe u svakodnevnim uslovima - uz različito osvetljenje, pozadinu, rezoluciju i ugao snimanja. Ova raznolikost je značajna jer model uči da prepozna znak nezavisno od konkretne osobe i uslova snimanja.

Prvobitno je u predlogu projekta bio predviđen skup Google Isolated Sign Language Recognition (ISLR). Tokom rada se pokazalo da pristup tom skupu zahteva verifikaciju naloga koja nije bila izvodljiva, pa je odabran ASL Citizen kao alternativa. Metodologija je ostala nepromenjena, budući da oba skupa pripadaju istom problemu prepoznavanja izolovanih znakova; razlika je u tome što ASL Citizen sadrži video snimke iz kojih se ključne tačke izdvajaju samostalno, dok ISLR pruža već izdvojene tačke.

2.1. Izbor podskupa znakova

Imajući u vidu obim projekta i ograničene računске resurse, iz skupa je izabran podskup od 25 znakova. Birani su znakovi koji u sva tri podskupa (trening, validacija, test) imaju najveći broj primera, čime je obezbeđeno da svaki znak ima dovoljno primera za obuku i pouzdanu evaluaciju. Ukupno je korišćeno 973 video snimka: 497 za trening, 96 za validaciju i 380 za testiranje.

Izabrani znakovi su: DOG, HURDLE/TRIP, DEMAND, BITE, DARK, BREAKFAST, MECHANIC, PARTY, ROCKINGCHAIR, DEAF, WHATFOR, DECIDE, FINE, NOON, HALLOWEEN, DEVELOP, LUNCH, EDIT, SHAVE, BACKPACK, BEE, BELT, PATIENT, CHRISTMAS i RIVER.

2.2. Podela podataka po osobi

Ključna karakteristika korišćene podele je da je izvršena po osobi: 35 osoba čini trening skup, dok se test skup sastoji od 11 potpuno različitih osoba koje se ne pojavljuju tokom obuke. Ovakva podela je važna jer sprečava da model zapamti konkretne osobe i time veštački poveća prividnu tačnost. Pošto se model testira isključivo na osobama koje nije video tokom obuke, izmerena tačnost realno odražava njegovu sposobnost da prepozna znak kod nove osobe.

3. Korišćene tehnologije

U izradi projekta korišćene su sledeće tehnologije:

- Python - osnovni programski jezik u kome je realizovan ceo sistem.
- MediaPipe - biblioteka kompanije Google za izdvajanje ključnih tačaka šaka i tela. Korišćeni su moduli HandLandmarker (za šake) i PoseLandmarker (za pozu).
- PyTorch - okvir za duboko učenje, korišćen za implementaciju i obuku LSTM i Transformer modela.


- OpenCV - biblioteka za rad sa slikama i video snimcima, korišćena za čitanje frejmova iz video fajlova.
- NumPy i Pandas - biblioteke za numeričke operacije i rad sa tabelarnim podacima.
- Matplotlib i scikit-learn - za vizuelizaciju rezultata i računanje metrika (konfuziona matrica).
- Google Colab - okruženje sa besplatnim pristupom grafičkoj kartici (GPU), korišćeno za obuku modela.

4. Arhitektura sistema

Sistem je organizovan kao niz faza kroz koje podaci prolaze od sirovog video snimka do prepoznatog znaka. Glavne komponente sistema su:

- Ekstrakcija ključnih tačaka - svaki video se pomoću MediaPipe pretvara u niz koordinata šaka i poze.
- Priprema sekvenci - nizovi različite dužine se svode na jedinstvenu dužinu, uz uklanjanje praznih delova.
- Normalizacija - koordinate se centriraju i skaliraju tako da budu nezavisne od položaja osobe u kadru.
- Augmentacija - tokom obuke se generišu blago izmenjene varijante primera radi bolje generalizacije.
- Model - LSTM ili Transformer mreža koja na osnovu niza tačaka predviđa znak.
- Evaluacija - merenje tačnosti i analiza grešaka na test skupu.

Sistem je organizovan kao niz faza kroz koje podaci prolaze od sirovog video snimka do prepoznatog znaka. Faze ekstrakcije i pripreme podataka izvršavaju se jednom, a rezultat (nizovi ključnih tačaka) se čuva i koristi za obuku oba modela. Time se obuka, koja se izvodi više puta, odvaja od spore ekstrakcije koja se izvodi jednom.



Slika 1


5. Obrada podataka

5.1. Ekstrakcija ključnih tačaka

Svaki video snimak se obrađuje frejm po frejm pomoću alata MediaPipe. Iz svakog frejma se izdvajaju koordinate ključnih tačaka: 21 tačka za levu šaku, 21 tačka za desnu šaku i 12 tačaka poze koje obuhvataju ramena, laktove i ručne zglobove. Svaka tačka ima tri koordinate (x, y, z), pa jedan frejm opisuje ukupno 162 vrednosti ($2 \times 21 \times 3$ za šake i 12×3 za pozu).

Tačke lica, iako ih MediaPipe može izdvojiti, nisu korišćene. Za prepoznavanje izolovanih znakova izraz lica ne nosi značajnu informaciju, a njihovo uključivanje bi znatno povećalo dimenziju ulaza. Fokus je stoga na šakama, koje nose najveći deo informacije o znaku, i na gornjem delu tela koji opisuje gde se znak izvodi u odnosu na telo.

Tačke koje MediaPipe ne uspe da detektuje u nekom frejmu (na primer kada je šaka van kadra) popunjavaju se nulama. Rezultat ekstrakcije za svaki video je matrica oblika [broj frejmova $\times$ 162], koja se čuva radi dalje upotrebe.



Slika 2

5.2. Priprema sekvenci

Video snimci imaju različite dužine, u korišćenom podskupu od 10 do preko 500 frejmova, sa medijanom oko 72 frejma. Pošto neuronske mreže zahtevaju ulaz fiksne dužine, sve sekvence se svode na 64 frejma. Sekvence duže od 64 frejma se ravnomerno proređuju (bira se 64 frejma raspoređena kroz ceo pokret, čime se zadržava i početak i kraj znaka), dok se kraće dopunjavaju nulama. Uz svaku sekvencu se čuva i maska koja označava koji su frejmovi stvarni, a koji su dodati kao dopuna.

Analizom podataka uočeno je da na početku i kraju snimaka osoba često drži ruke spuštene, pa MediaPipe u tim frejmovima ne detektuje šake. Pre svođenja na fiksnu dužinu, svaka sekvenca se stoga iseca na opseg u kome su šake aktivne. Ovim postupkom je udeo frejmova sa detektovanim šakama povećan sa približno 43% na približno 92%, čime model dobija znatno čistiji signal.

5.3. Normalizacija

Sirove koordinate koje vraća MediaPipe zavise od toga gde se osoba nalazi u kadru i koliko je udaljena od kamere. Da bi model učio oblik pokreta, a ne apsolutni položaj, koordinate se normalizuju. Svaki frejm se centrira oko sredine ramena (tačke koje MediaPipe uvek označava istim rednim brojevima), a zatim skalira širinom ramena. Na taj način isti znak ima isti numerički opis bez obzira na to gde osoba stoji i koliko je blizu kamere.

Tokom implementacije uočeno je da u retkim frejmovima razmak između ramena može biti veoma mali, što pri deljenju dovodi do ekstremno velikih vrednosti. Da bi se to sprečilo, uvedena je minimalna vrednost razmaka ramena, a sve koordinate su ograničene (klipovane) na razuman opseg. Ova zaštita je bila neophodna za stabilnu obuku Transformer modela.

5.4. Augmentacija podataka

Pošto svaki znak ima relativno mali broj primera (oko 20 u trening skupu), postoji rizik da model zapamti konkretne primere umesto da nauči suštinu znaka. Da bi se to ublažilo, tokom obuke se primenjuje augmentacija: pri svakom prolasku kroz podatke svaka sekvenca se blago izmeni nasumičnom rotacijom, skaliranjem, pomeranjem, dodavanjem šuma na koordinate i variranjem brzine pokreta. Pošto se radi sa koordinatama, a ne sa slikama, ove transformacije su računski jeftine i izvode se u toku obuke.

Augmentacija primorava model da nauči zajedničke osobine svih varijanti istog znaka, čime se poboljšava generalizacija na nove osobe. Njen efekat je i izmeren - tačnost LSTM modela na test skupu porasla je sa približno 64% na približno 70% nakon uvođenja augmentacije.

6. Implementirani modeli

Oba modela rešavaju isti zadatak: na osnovu niza ključnih tačaka (oblika $[64 \times 162]$) predviđaju koji je od 25 znakova u pitanju. Razlikuju se u načinu na koji obrađuju vremensku dimenziju sekvence.

6.1. LSTM model

LSTM (Long Short-Term Memory) je vrsta rekurentne neuronske mreže koja obrađuje sekvencu redom, frejm po frejm, i pri tom održava interno pamćenje o prethodnim frejmovima. Time je pogodna za podatke kod kojih je redosled bitan, kao što je pokret kroz vreme. Implementirani model koristi dvosmernu LSTM mrežu (koja sekvencu čita i unapred i unazad) sa dva sloja, nakon čega sledi potpuno povezani sloj koji daje verovatnoće za svaki od 25 znakova. Model ima približno 730.000 parametara.

Prednost LSTM čeli je u odnosu na običnu rekurentnu mrežu je u tzv. kapijama (engl. gates) - mehanizmima koji regulišu koje se informacije iz prethodnih frejmova zadržavaju, a koje zaboravljaju. Zahvaljujući tome, mreža može da uči zavisnosti između udaljenih frejmova, što je važno kod znakova kod kojih je bitan ceo tok pokreta, a ne samo pojedinačni trenutak. Korišćena je dvosmerna (bidirekciona) varijanta, koja sekvencu obrađuje istovremeno u oba smera, od početka ka kraju i obrnuto, čime se za svaki frejm koristi kontekst i onoga što mu prethodi i onoga što sledi.

6.2. Transformer model

Transformer obrađuje celu sekvencu istovremeno i koristi mehanizam pažnje (self-attention) kojim određuje koji su frejmovi međusobno najvažniji za prepoznavanje znaka. Pošto sam po sebi ne poznaje redosled frejmova, dodaje se poziciono kodiranje koje nosi informaciju o položaju svakog frejma u sekvenci. Implementirani model koristi tri Transformer enkoder sloja, nakon kojih sledi klasifikacioni sloj. Model ima približno 438.000 parametara, dakle znatno manje od LSTM modela.

Ključni deo Transformer arhitekture je mehanizam pažnje (self-attention), koji za svaki frejm izračunava koliko je povezan sa svim ostalim frejmovima u sekvenci. Na taj način model može direktno da poveže udaljene delove pokreta, bez potrebe da informaciju „prenosi“ korak po korak kao rekurentna mreža. Pošto mehanizam pažnje sam po sebi ne razlikuje redosled frejmova, dodaje se poziciono kodiranje - skup vrednosti koje svakom frejmu pridružuju informaciju o njegovom položaju u sekvenci. Sposobnost da se svi frejmovi porede istovremeno može biti razlog zašto je Transformer, i pored manjeg broja parametara, ostvario bolju tačnost od LSTM modela.

6.3. Postupak obuke

Oba modela su obučavana pod istim uslovima - sa istom augmentacijom, istim brojem epoha i istim načinom biranja najboljeg modela. Kao funkcija gubitka korišćena je unakrsna entropija, a kao optimizacioni algoritam AdamW. Tokom obuke se pratila tačnost na validacionom skupu i čuvao model sa najboljom validacionom tačnošću, koji je potom evaluiran na test skupu. Kod Transformer modela bilo je potrebno dodatno stabilizovati obuku ograničavanjem gradijenata i postepenim povećanjem stope učenja na početku, kako bi se sprečila numerička nestabilnost.

7. Rezultati i analiza

Za ocenu uspešnosti modela korišćeno je nekoliko standardnih metrika. Osnovna metrika je tačnost (engl. accuracy) - udeo ispravno prepoznatih znakova u ukupnom broju primera. Pored ukupne tačnosti, praćena je i tačnost po pojedinačnom znaku, koja pokazuje koliko dobro model prepoznaje svaki znak posebno. Za detaljniju analizu grešaka korišćena je konfuzionna matrica - tabela u kojoj red predstavlja stvarni znak, a kolona znak koji je model predvideo; vrednosti na glavnoj dijagonali predstavljaju ispravne predikcije, dok vrednosti van dijagonale pokazuju koje znakove model međusobno meša. Kao referentna vrednost korišćena je i tačnost nasumičnog pogađanja, koja za 25 znakova iznosi približno 4% (1/25); svaki rezultat znatno iznad te vrednosti pokazuje da model stvarno uči da razlikuje znakove.


7.1. Poređenje modela

Tačnost oba modela na test skupu, koji čine osobe neviđene tokom obuke, prikazana je u sledećoj tabeli. Za 25 znakova nasumično pogađanje dalo bi tačnost od oko 4%, pa su ostvareni rezultati znatno iznad slučajnog nivoa.

Model	Validacija	Test	Parametara
LSTM	68.8%	67.6%	730.393
Transformer	78.1%	75.3%	438.297

Tabela 1. Poređenje tačnosti i veličine modela.

Transformer model je ostvario bolju tačnost od LSTM modela (75.3% naspram 67.6%), i to sa približno upola manje parametara. Ovaj rezultat je zanimljiv jer se kod manjih skupova podataka često očekuje da Transformer arhitektura zaostane za rekurentnim mrežama; na korišćenim podacima mehanizam pažnje se ipak pokazao efikasnijim.



Slika 3

Na slici je prikazan tok obuke oba modela - kretanje tačnosti na validacionom skupu kroz 80 epoha. U prvih dvadesetak epoha oba modela brzo napreduju, nakon čega se krive razdvajaju: Transformer nakon približno tridesete epohe dostiže i zadržava viši nivo tačnosti od LSTM modela. Kod oba modela tačnost se pri kraju obuke stabilizuje, što ukazuje da dalje produžavanje obuke ne bi donelo značajno poboljšanje. Grafik potvrđuje nalaz iz tabele rezultata - Transformer model ostvaruje bolju tačnost na validacionom skupu.

Radi šireg konteksta, ostvareni rezultati se mogu uporediti sa objavljenim rezultatima autora skupa ASL Citizen. U originalnom radu (Desai i dr., 2023) modeli postižu tačnost od približno 63% na celom skupu od 2.731 znaka, uz evaluaciju isključivo na osobama koje se ne pojavljuju u trening skupu - isti princip podele po osobi primenjen je i u ovom radu. Direktno poređenje tačnosti nije moguće, budući da je u ovom projektu korišćen podskup od 25 znakova, što je znatno jednostavniji zadatak od prepoznavanja svih 2.731 znaka. Ipak, činjenica da su ostvarene tačnosti (67,6% za LSTM i 75,3% za Transformer) na sličnom ili višem nivou uprkos manjem broju primera po znaku, uz istu strogu podelu podataka po osobi, ukazuje da primenjena metodologija daje rezultate konzistentne sa objavljenim pristupima.

7.2. Analiza grešaka


Analizom konfuzionih matrica oba modela uočeno je da se greške koncentrišu na određene parove znakova. Posebno je značajno to što oba modela najčešće mešaju slične parove - na primer LUNCH i CHRISTMAS, NOON i CHRISTMAS, PARTY i BACKPACK itd. Činjenica da se greške javljaju na sličnim parovima ukazuje da su ti znakovi objektivno slični po pokretu, a ne da

je reč o slabosti jednog modela. To takođe potvrđuje da modeli uče smislene reprezentacije pokreta.


Iz tabele se vidi da se tačnost znatno razlikuje među znakovima. Najteži su LUNCH, CHRISTMAS i BREAKFAST, kod kojih tačnost pada i ispod 55%, dok se znakovi poput DOG, DARK i MECHANIC prepoznaju gotovo bez greške. Uočava se i da su najteži znakovi upravo oni koji se u konfuzionoj matrici najčešće mešaju sa drugima, što potvrđuje da su ti znakovi objektivno slični po pokretu. Transformer model je na većini znakova jednako uspešan ili uspešniji od LSTM modela, u skladu sa razlikom u ukupnoj tačnosti.

Znak	Test primera	LSTM (%)	Transformer (%)
LUNCH	14	29	29
DEAF	15	67	40
CHRISTMAS	17	24	53
BREAKFAST	15	27	53
SHAVE	15	73	53
NOON	15	73	60
HURDLE/TRIP	13	85	62
BEE	14	43	64
DECIDE	15	73	67
DEMAND	14	79	71
PARTY	15	67	73
WHATFOR	18	78	78
ROCKINGCHAIR	15	60	80
RIVER	15	67	80
BACKPACK	15	67	80
FINE	16	81	81
BITE	14	79	86
BELT	18	83	89
EDIT	15	73	93
HALLOWEEN	14	86	93
DEVELOP	14	79	93
PATIENT	16	38	94
DOG	17	88	100
DARK	15	87	100
MECHANIC	16	88	100

Tabela 2. Tačnost oba modela po pojedinačnom znaku na test skupu, sortirano od znakova koje modeli najteže prepoznaju ka onima koje prepoznaju najpouzdanije.



Slika 4



Slika 5

Tačnost po pojedinačnim znakovima kreće se u širokom rasponu, od oko 29% za znakove koji se lako mešaju sa drugima (LUNCH), preko znakova srednje težine (CHRISTMAS i BREAKFAST oko 53%), do 100% za znakove sa jasno prepoznatljivim pokretom (DOG, DARK, MECHANIC). Ovaj raspon je u skladu sa nalazima konfuzione matrice.

7.3. Vizuelizacija

Radi provere i ilustracije rada sistema, implementirana je vizuelizacija ključnih tačaka u vidu pojednostavljenog skeleta šaka i ramena. Animacijom sačuvane sekvence prikazuje se pokret onako kako ga model vidi - kao niz tačaka kroz vreme - zajedno sa predikcijom modela. Ova vizuelizacija je korisna i za razumevanje grešaka, jer se kod pogrešno klasifikovanih primera vizuelno uočava sličnost pokreta sa znakom koji je model predvideo.

8. Problemi i rešenja

Tokom izrade projekta naišlo se na nekoliko tehničkih problema čije rešavanje je bilo sastavni deo rada:

- Pristup podacima - prvobitno predviđeni skup ISLR nije bio dostupan bez verifikacije naloga, pa je odabran ASL Citizen uz istu metodologiju.
- Kompatibilnost biblioteka - novije verzije MediaPipe nisu podržavale stari način pristupa modelima, pa je korišćen noviji API (HandLandmarker i PoseLandmarker) umesto ranije predviđenog Holistic modela.
- Numerička nestabilnost - pri obuci Transformer modela javljale su se nedefinisane vrednosti usled ekstremnih koordinata nastalih u normalizaciji. Problem je rešen ograničavanjem razmaka ramena, klipovanjem koordinata i ograničavanjem gradijenata.
- Veličina podataka i okruženje - zbog veličine video skupa, ekstrakcija ključnih tačaka je organizovana tako da se može prekinuti i nastaviti, a obrađene tačke se trajno čuvaju kako se spora ekstrakcija ne bi ponavljala.

9. Zaključak

U okviru projekta razvijen je kompletan sistem za prepoznavanje izolovanih znakova znakovnog jezika na osnovu ključnih tačaka šaka i tela. Implementirana su i upoređena dva modela - LSTM i Transformer - pri čemu je Transformer ostvario bolju tačnost (75.3%) uz manji broj parametara. Rezultati su dobijeni uz poštnu podelu podataka po osobi, pa odražavaju realnu sposobnost sistema da prepozna znak kod nepoznate osobe.

Glavna ograničenja projekta proističu iz relativno malog broja primera po znaku, što ograničava maksimalnu dostižnu tačnost, kao i iz sužavanja na podskup od 25 znakova. Uprkos tome, ostvareni rezultati i konzistentnost grešaka pokazuju da modeli uče smislene obrasce pokreta.

Kao mogući pravci daljeg razvoja izdvajaju se: proširenje na veći broj znakova, dodavanje sopstvenih snimaka radi povećanja broja primera, kao i realizacija demonstracije u realnom vremenu putem web kamere, kod koje bi se ključne tačke izdvajale uživo i prosleđivale obučenom modelu. Time bi sistem dobio i praktičnu, interaktivnu primenu.

10. Literatura

- Desai A. i dr., ASL Citizen: A Community-Sourced Dataset for Advancing Isolated Sign Language Recognition, Microsoft Research, 2023.
- Vaswani A. i dr., Attention Is All You Need, NeurIPS, 2017.
- Hochreiter S., Schmidhuber J., Long Short-Term Memory, Neural Computation, 1997.
- MediaPipe dokumentacija, Google, <https://developers.google.com/mediapipe>
- PyTorch dokumentacija, <https://pytorch.org/docs>